

PROJET BOTTLENECK

Dossier de veille, cahier des charges et documentation

Analyse du stock et des ventes — Bottleneck



Oumou Salam KANE

Data Analyst- Promo 5
27/07/2026

Ce dossier regroupe les trois livrables attendus en complément du notebook d'analyse : **la veille métier et technologique, le cahier des charges fonctionnel et la documentation des tests, décisions et limites.**

Sommaire

1. Veille métier et technologique

1.1 Grille de lecture des critères

2. Cahier des charges fonctionnel

2.1 Contexte et besoin

2.2 Périmètre

2.3 Contraintes

2.4 Critères de réussite

2.5 Livrables

3. Documentation des tests et décisions

3.1 Détection des valeurs aberrantes (prix)

3.2 Traitement des valeurs aberrantes détectées

3.3 Visualisation des indicateurs

3.5 Cohérence avec les principes de développement durable

4. Accompagnement et gouvernance du projet

4.1 Plan de formation pour les métiers

4.2 Points de contrôle : revues, validation, versioning

1. Veille métier et technologique

Cette partie recense, pour chaque choix technique du projet, **les solutions identifiées** (outils, méthodes, y compris pistes IA), **les sources** consultées et **les critères** ayant guidé la décision finale. Une ligne = un arbitrage documenté dans le notebook.

Besoin	Solutions identifiées	Sources	Critères de choix	Décision retenue
Détecter les prix atypiques	Z-score (moyenne/écart-type) ; IQR (quartiles)/ Règle de Tukey	Documentation/cours de statistiques descriptives, échange documenté avec une IA	Robustesse aux valeurs extrêmes ; adéquation à une distribution asymétrique ; sobriété (proportion calcul/volume)	IQR retenu (seuil 83,10 €, 36 articles) ; ML écarté car disproportionné pour 822 articles
Traiter les valeurs détectées	Suppression ; conservation avec marquage (flag)	Bonnes pratiques de qualité des données	Traçabilité, réversibilité ; impact sur le CA et les indicateurs	Marquage (flag outlier_iqr) : préserve le CA réel, liste exportable pour validation métier
Visualiser les palmarès et distributions	Seaborn, Plotly Express (interactif)	Documentation officielle des deux librairies	Lisibilité du rendu, code simple et optimal	Plotly pour les analyses interactives telles que le CA, le stock... Seaborn pour les graphiques statiques(boxplot, heatmap)

1.1 Grille de lecture des critères

Rappel des critères mobilisables pour chaque arbitrage (à adapter selon le sujet) :

- **Qualité** : le résultat répond-il correctement au besoin métier ?
- **Biais** : la méthode favorise-t-elle ou pénalise-t-elle certains cas de façon injustifiée ?
- **Temps / effort** : coût de mise en œuvre et de maintenance.
- **Reproductibilité** : le résultat est-il stable si les données évoluent ?
- **Sécurité / conformité** : traçabilité des anomalies, respect des données sources.
- **Sobriété / impact** : la solution est-elle proportionnée au volume de données et aux ressources nécessaires ?

2. Cahier des charges fonctionnel

2.1 Contexte et besoin

Mission confiée par Nicolas, manager du service, dans le cadre d'une intégration au sein de l'équipe data de Bottleneck (vente de vins et spiritueux en ligne). L'entreprise exploite aujourd'hui trois exports distincts pour analyser son activité : un extrait ERP (référence produit, prix, état du stock), un extrait du site web (SKU, quantités vendues, description des produits) et une table de liaison entre les deux, les identifiants ne se correspondant pas d'un système à l'autre. Cette table a été mise à jour par le stagiaire du service pour intégrer les nouveaux produits.

La mission se déroule en deux phases :

-Phase 1 — agréger les trois fichiers pour les rendre exploitables ;

-Phase 2 — analyser les données et restituer les résultats à l'oral devant le comité de direction (CODIR), qui sera aussi l'occasion d'une présentation à l'équipe de direction de l'entreprise.

2.2 Périmètre

Phase 1 — Agrégation des données :

- Rapprocher l'extraction du site web avec la base ERP via la table de liaison
- Identifier les erreurs présentes dans les données : erreurs de saisie, de type, de calcul, de jointure, etc.
- Proposer des solutions concrètes pour améliorer la qualité des données dans les systèmes sources (ERP, site web)

Phase 2 — Analyse pour le CODIR :

- Détection des valeurs aberrantes (Z-score et/ou IQR) pour vérifier d'éventuelles erreurs de saisie ;
- Extraction des valeurs aberrantes de prix (boxplot) et conclusion sur la présence d'erreurs de prix afin de les remonter au métier ;
- Chiffre d'affaires par produit et total général ;
- Tops références de vente et règle des 20/80 ;
- Analyse de l'état des stocks, du taux de marge, de la rotation de stock et du nombre de mois de stock pour chaque produit.

2.3 Contraintes

- Les identifiants produits ne correspondent pas entre l'ERP et le site web : toute jointure doit impérativement passer par la table de liaison
- Conformité : toute anomalie de donnée est documentée et remontée, jamais corrigée arbitrairement dans les systèmes sources
- La qualité des données doit être vérifiée avant toute analyse : doublons, valeurs manquantes, incohérences, valeurs aberrantes ;
- Traitements réalisés en Python dans un notebook Jupyter, avec les bibliothèques pandas, NumPy, Plotly Express et Seaborn/Matplotlib.
- Projet à réaliser dans le délai imparti

- Public de la restitution : comité de compréhensible par un public non technique, mettant en évidence les indicateurs clés (ventes, stocks, anomalies), alignée sur leurs préoccupations (rentabilité, fiabilité des données, état des stocks)
- RGPD : non applicable en l'état, aucune donnée personnelle identifiée dans les exports traités (ERP, site e-commerce, table de liaison) ; à réévaluer si le périmètre des données venait à évoluer.

2.4 Critères de réussite

- Jointure ERP - site web réalisée via la table de liaison, avec taux de correspondance connu et expliqué
- Erreurs identifiées et catégorisées (saisie, type, calcul, jointure...), chacune avec une solution d'amélioration proposée
- Chiffre d'affaires calculé par produit et en total général
- Tops références et règle du 20/80 établis
- Valeurs aberrantes détectées (Z-score et/ou IQR), confrontées à un boxplot des prix, avec une conclusion explicite sur la présence ou non d'erreurs de prix
- État des stocks, taux de marge et rotation de stock (mois de stock) analysés
- Chaque choix technique comparé à au moins une alternative et justifié par des critères explicites
- Présentation finale synthétique, compréhensible par un public non technique (CODIR)

2.5 Livrables

- Phase 1 : notebook Python documentant l'agrégation des trois fichiers, les erreurs identifiées et les solutions proposées
- Phase 2 : support de présentation synthétique destiné au CODIR (analyses alignées sur leurs préoccupations)
- Présent dossier : veille technologique, cahier des charges, documentation des décisions

3. Documentation des tests et décisions

Une fiche par sujet traité. Chaque fiche répond à la même trame : hypothèse testée, tests réalisés, résultats chiffrés, décision prise, et ce qui est écarté (avec la raison) ainsi que les limites et pistes d'amélioration identifiées.

3.1 Détection des valeurs aberrantes (prix)

Hypothèse testée	Le choix de la méthode statistique (Z-score vs IQR) influence significativement le nombre et la nature des valeurs détectées comme aberrantes.
Tests réalisés	Calcul des deux seuils sur les 822 prix (Z-score = moyenne + 3σ ; IQR = $Q3 + 1,5 \times IQR$) ; comparaison croisée des détections (tableau croisé) ; inspection métier des articles en désaccord entre les deux méthodes.
Résultats	Seuil Z-score = 112,22 € → 17 articles détectés. Seuil IQR = 83,10 € → 36 articles détectés, incluant strictement les 17 du Z-score. Les 19 articles supplémentaires (zone 83–112 €) sont des références premium légitimes (grands crus, champagnes de vigneron, whisky single cask).
Décision	Méthode IQR retenue : robuste aux valeurs extrêmes, sans hypothèse de normalité, adaptée à la distribution asymétrique des prix (médiane 24,40 € < moyenne 32,35 €).
Écarté / non retenu	Z-score écarté : sous-détecte car son seuil est gonflé par les valeurs extrêmes qu'il doit repérer. Méthodes de machine learning (Isolation Forest, DBSCAN) identifiées en veille mais écartées : disproportionnées pour 822 articles et moins interprétables pour le métier.
Limites / pistes d'amélioration	Seuil global non différencié par type de produit (un whisky à 93 € n'est pas atypique parmi les whiskies) → piste : calculer un seuil IQR par catégorie de produit, sous réserve d'effectifs suffisants par catégorie.

3.2 Traitement des valeurs aberrantes détectées

Hypothèse testée	Supprimer les 36 outliers détectés donnerait des statistiques "plus propres" sans dénaturer l'analyse globale.
Tests réalisés	Comparaison de deux variantes : (A) suppression des 36 articles ; (B) conservation avec marquage (flag outlier_iqr). Calcul du prix moyen dans les deux cas.
Résultats	Variante A : 786 articles restants, prix moyen 28,30 €. Variante B : 822 articles conservés, 36 marqués ; prix moyen avec outliers 32,35 €, sans 28,30 €. Écart de 4,05 € (–12,5 %) sur le prix moyen selon qu'on inclut ou non les outliers.

Décision	Variante B (marquage) retenue : les 36 articles sont atypiques mais légitimes et contribuent réellement au chiffre d'affaires ; le flag permet de calculer, à la demande, la moyenne "avec" ou "sans" ces articles.
Écarté / non retenu	Suppression (A) écartée : irréversible, sans trace, aurait faussé le CA et le palmarès des ventes en retirant de vraies ventes premium.
Limites / pistes d'amélioration	La validation métier des 36 articles n'est pas encore bouclée → piste : soumettre la liste aux équipes, puis intégrer leur retour (statut confirmé / erreur à corriger) dans une prochaine itération.

3.3 Visualisation des indicateurs

Hypothèse testée	Seaborn et Plotly Express répondent à des besoins différents (support figé vs exploration interactive) plutôt qu'un outil ne surclassant l'autre.
Tests réalisés	Réalisation du même graphique (boîte à moustaches des prix) avec les deux librairies ; comparaison sur l'interactivité, la portabilité et le poids du notebook.
Résultats	Seaborn : rendu statique, léger, exportable facilement en image pour un rapport. Plotly : interactif (survol des valeurs), utile sur les palmarès à libellés longs, mais notebook plus lourd.
Décision	Usage combiné : Plotly pour les palmarès (top 20 CA, quantités, rotation de stock) ; Seaborn pour les graphiques statistiques destinés à un support figé (boxplot, heatmap de corrélation).
Écarté / non retenu	Un choix unique ("tout en Plotly" ou "tout en Seaborn") écarté : aurait sacrifié soit la lisibilité interactive des palmarès, soit la simplicité d'export pour la présentation.
Limites / pistes d'amélioration	

3.4 Cohérence avec les principes de développement durable

Les choix techniques privilégient la sobriété : méthodes statistiques simples et proportionnées au volume de données traité (IQR plutôt que des algorithmes de machine learning plus coûteux en calcul, identifiés en veille mais jugés disproportionnés pour 822 articles), outils open source ne nécessitant pas d'infrastructure dédiée, conservation des données plutôt que leur destruction (marquage), et amélioration de la qualité des données à la source pour limiter les retraitements futurs.

4. Accompagnement et gouvernance du projet

4.1 Plan de formation pour les métiers

Objectif : permettre aux équipes métier (CODIR, achats, gestion des stocks) de **comprendre les KPI, interpréter les graphiques, identifier les anomalies** et **exploiter les résultats pour la prise de décision**. Trois formats ont été comparés.

Critère	A — Session dédiée séparée	B — Intro intégrée à la restitution CODIR	C — Guide de lecture écrit (1 page)
Temps requis	Élevé (30-45 min supplémentaires à obtenir)	Faible (2-3 min ajoutées à la présentation déjà prévue)	Aucune réunion, mais risque de non-lecture seul
Adapté à l'agenda d'un CODIR	Peu réaliste : créneau dédié difficile à obtenir	Réaliste : s'insère dans un rendez-vous déjà planifié	Réaliste mais isolé du moment où l'info est utile
Adoption réelle	Bonne si elle a lieu, mais souvent reportée/annulée	Bonne : les codes de lecture sont donnés juste avant d'en avoir besoin	Risque de ne jamais être relu sans un rappel
Réutilisable pour les prochains rapports	Non (formation ponctuelle, non recyclée)	Non à elle seule	Oui : reste disponible en autonomie

Décision retenue : formats B + C combinés. Une session dédiée séparée (A) est écartée : disproportionnée par rapport au temps qu'un CODIR peut consacrer à de la pédagogie pure, alors que l'objectif (comprendre ce rapport) peut être atteint en intégrant l'explication au moment même où elle sert. En pratique : quelques minutes d'introduction pédagogique en tout début de la présentation CODIR, complétées par un guide de lecture d'une page laissé aux participants pour les prochains rapports.

Contenu du guide de lecture (1 page), organisé en 4 volets :

- **Comprendre les KPI** : chiffre d'affaires (par produit et total), top références et règle du 20/80 (20 % des références réalisent 80 % du CA), taux de marge, rotation de stock / nombre de mois de stock.
- **Interpréter les graphiques** : lecture d'un boxplot (la boîte = la moitié centrale des valeurs, le trait = la médiane, les points isolés = valeurs atypiques) ; lecture d'un palmarès en barres à dégradé de couleur (plus la couleur est intense, plus la valeur est élevée).
- **Identifier les anomalies** : un point isolé sur un boxplot ou un article marqué "atypique" n'est pas automatiquement une erreur — il peut s'agir d'un produit premium légitime (cf. section 3.1) ; une

valeur impossible (prix ≤ 0 , mois de stock infini) est en revanche une vraie anomalie de données, déjà traitée en amont.

- **Exploiter pour la décision** : exemples concrets — un article à mois de stock très élevé signale un risque de surstock (piste : déstockage ou promotion) ; un article du top CA doit être sécurisé en approvisionnement ; une catégorie à faible taux de marge mérite une révision du pricing.

4.2 Points de contrôle : revues, validation, versioning

- **Revue hebdomadaire** avec le manager (Nicolas) : point d'avancement, blocages, arbitrages en attente.
- **Validation intermédiaire (fin de L2 et L4)** : le dataset consolidé et les premières analyses sont revus avant de passer à la restitution pour éviter de présenter des résultats bâtis sur des données non fiabilisées.
- **Versioning du notebook** : une version numérotée à chaque jalon (v1_data_audit, v2_nettoyage, v3_analyses, v4_final), conservée même après modification, pour pouvoir revenir en arrière et justifier l'historique des décisions.
- **Revue finale du support** avant la présentation CODIR : relecture par le manager, vérification de l'alignement avec les préoccupations de la direction (rentabilité, fiabilité des données, état des stocks).